Машинное обучение — 1. Теоретические задачи Каргальцев Степан 26.02.2017

1. Наивный байес и центроидный классификатор

Покажите, что если в наивном байесовском классификаторе классы имеют одинаковые априорные вероятности, а плотность распределения признаков в каждом классе имеет вид $P(x^{(k)}|y) = \frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(x^{(k)}-\mu_{yk})^2}{2\sigma^2}}, x^{(k)}, k=1\dots n-n$ ризнаки объекта x, классификация сводится κ отнесению объекта x к классу y, центр которого $\mu_y = (\mu_1, \dots, \mu_n)^T$ ближе всего κ x.

$$\hat{y} = \operatorname*{argmax}_y \left[\prod_{k=1}^n P(x^{(k)}|y) P(y) \right] = |P(y) \text{ одинаковы}| = \operatorname*{argmax}_y \left[\prod_{k=1}^n P(x^{(k)}|y) \right] =$$

$$\underset{y}{\operatorname{argmax}} \left[\prod_{k=1}^{n} \ln P(x^{(k)}|y) \right] = \underset{y}{\operatorname{argmax}} \left[-\sum_{k=1}^{n} \frac{(x^{(k)} - \mu_{yk})^{2}}{2\sigma^{2}} - \frac{1}{2} \ln(2\pi\sigma^{2}) \right] = \underset{y}{\operatorname{argmin}} \left[\sum_{k=1}^{n} (x^{(k)} - \mu_{yk})^{2} \right] = \underset{y}{\operatorname{argmax}} \left[-\sum_{k=1}^{n} \frac{(x^{(k)} - \mu_{yk})^{2}}{2\sigma^{2}} - \frac{1}{2} \ln(2\pi\sigma^{2}) \right] = \underset{y}{\operatorname{argmin}} \left[\sum_{k=1}^{n} (x^{(k)} - \mu_{yk})^{2} \right] = \underset{y}{\operatorname{argmin}} \left[\sum_{k=1}^{n} (x^{(k)}$$

$$\underset{y}{\operatorname{argmin}} \, \rho(x, \mu_y)$$

2. ROC-AUC случайных ответов

Покажите, что «треугольный ROC-AUC» (см.лекцию 2) в случае, когда классификатор дает случайные ответы – a(x)=1 с вероятностью p и a(x)=0 с вероятностью 1-p, будет в среднем равен 0.5, независимо от p и доли класса 1 в обучающей выборке.

Если пороговое значение 0 (то есть все ответы положительны), то мы получаем TPR=1, FPR=1 и точку (1,1)

Если пороговое значение 1 (то есть все ответы отрицательны), то мы получаем TPR = 0, FPR = 0 и точку (0, 0)

Иначе мы получаем TPR =
$$\frac{\sum\limits_{x\in 1}a(x)}{|1|}=:\mathcal{Y},$$
 FRP = $\frac{\sum\limits_{x\in 0}a(x)}{|0|}=:\mathcal{X}.$

Площадь треугольника на этих трех точках равна $S = \frac{1}{2}(\mathcal{X}, \mathcal{Y}) \times (1, 1) = \frac{1}{2}(\mathcal{X} - \mathcal{Y}) = \frac{\sum\limits_{x \in 0} a(x)}{2|0|} - \frac{\sum\limits_{x \in 1} a(x)}{2|1|}$.

$$ES = \frac{1}{2}E\left[\frac{\sum\limits_{x \in 0} a(x)}{|0|} - \frac{\sum\limits_{x \in 1} a(x)}{|1|}\right] = \frac{\sum\limits_{x \in 0} Ea(x)}{2|0|} - \frac{\sum\limits_{x \in 1} Ea(x)}{2|1|} = \frac{1}{2}(Ea(x) - Ea(x)) = 0$$

То есть площадь под ROC - AUC кривой будет в среднем равна E(0.5 + S) = 0.5

3. Ошибка 1NN и оптимального байесовского классификатора

Утверждается, что метод одного ближайшего соседа асимптотически (при условии, что максимальное по всем точкам выборки расстояние до ближайшего соседа стремится к нулю) имеет матожидание ошибки не более чем вдвое больше по сравнению с оптимальным байесовским классификатором (который это матожидание минимизирует).

Покажите это, рассмотрев задачу бинарной классификации. Достаточно рассмотреть вероятность ошибки на фиксированном объекте x, m.к. матожидание ошибок на выборке размера V будет просто произведением V на эту вероятность. Байесовский классификатор ошибается на объекте x с вероятностью:

$$E_B = \min\{P(1|x), P(0|x)\}\$$

Условные вероятности будем считать непрерывными функциями от $x \in \mathbb{R}^m$, чтобы иметь возможность делать предельные переходы. Метод ближайшего соседа ошибается с вероятностью:

$$E_N = P(y \neq y_n)$$

3десь y — настоящий класс x, а y_n — класс ближайшего соседа x_n к объекту x в предположении, что в обучающей выборке n объектов, равномерно заполняющих пространство.

Докажите исходное утверждение, выписав выражение для E_N (принадлежность к классам 0 и 1 для объектов x и x_n считать независимыми событиями) и осуществив предельный переход по n.

$$E_N = P(1|x_n) \cdot P(0|x) + P(0|x_n) \cdot P(1|x) \rightarrow 2P(0|x)P(1|x) =$$

$$2\min\{P(0|x), P(1|x)\} \cdot \max\{P(0|x), P(1|x)\} \leq 2\min\{P(0|x), P(1|x)\} = 2E_B$$