

Машинное обучение – 1. Теоретические задачи

Каргальцев Степан

26.02.2017

1. Наивный байес и центроидный классификатор

Покажите, что если в наивном байесовском классификаторе классы имеют одинаковые априорные вероятности, а плотность распределения признаков в каждом классе имеет вид $P(x^{(k)}|y) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x^{(k)} - \mu_{yk})^2}{2\sigma^2}}$, $x^{(k)}$, $k = 1 \dots n$ — признаки объекта x , классификация сводится к отнесению объекта x к классу y , центр которого $\mu_y = (\mu_1, \dots, \mu_n)^T$ ближе всего к x .

$$\hat{y} = \operatorname{argmax}_y \left[\prod_{k=1}^n P(x^{(k)}|y) P(y) \right] = |P(y) \text{ одинаковы}| = \operatorname{argmax}_y \left[\prod_{k=1}^n P(x^{(k)}|y) \right] =$$
$$\operatorname{argmax}_y \left[\prod_{k=1}^n \ln P(x^{(k)}|y) \right] = \operatorname{argmax}_y \left[- \sum_{k=1}^n \frac{(x^{(k)} - \mu_{yk})^2}{2\sigma^2} - \frac{1}{2} \ln(2\pi\sigma^2) \right] = \operatorname{argmin}_y \left[\sum_{k=1}^n (x^{(k)} - \mu_{yk})^2 \right] =$$
$$\operatorname{argmin}_y \rho(x, \mu_y)$$

2. ROC-AUC случайных ответов

Покажите, что «треугольный ROC-AUC» (см. лекцию 2) в случае, когда классификатор дает случайные ответы — $a(x) = 1$ с вероятностью p и $a(x) = 0$ с вероятностью $1 - p$, будет в среднем равен 0.5, независимо от p и доли класса 1 в обучающей выборке.

Если пороговое значение 0 (то есть все ответы положительны), то мы получаем $\text{TPR} = 1$, $\text{FPR} = 1$ и точку $(1, 1)$

Если пороговое значение 1 (то есть все ответы отрицательны), то мы получаем $\text{TPR} = 0$, $\text{FPR} = 0$ и точку $(0, 0)$

Иначе мы получаем $\text{TPR} = \frac{\sum_{x \in 1} a(x)}{|1|} =: \mathcal{Y}$, $\text{FRP} = \frac{\sum_{x \in 0} a(x)}{|0|} =: \mathcal{X}$.

Площадь треугольника на этих трех точках равна $S = (\mathcal{X}, \mathcal{Y}) \times (1, 1) = \mathcal{X} - \mathcal{Y} = \frac{\sum_{x \in 0} a(x)}{|0|} - \frac{\sum_{x \in 1} a(x)}{|1|}$.

$$ES = E \left[\frac{\sum_{x \in 0} a(x)}{|0|} - \frac{\sum_{x \in 1} a(x)}{|1|} \right] = \frac{\sum_{x \in 0} Ea(x)}{|0|} - \frac{\sum_{x \in 1} Ea(x)}{|1|} = Ea(x) - Ea(x) = 0$$

То есть площадь под $ROC - AUC$ кривой будет в среднем равна $E(0.5 + S) = 0.5$

3. Ошибка 1NN и оптимального байесовского классификатора

Утверждается, что метод одного ближайшего соседа асимптотически (при условии, что максимальное по всем точкам выборки расстояние до ближайшего соседа стремится к нулю) имеет матожидание ошибки не более чем вдвое больше по сравнению с оптимальным байесовским классификатором (который это матожидание минимизирует).

Покажите это, рассмотрев задачу бинарной классификации. Достаточно рассмотреть вероятность ошибки на фиксированном объекте x , т.к. матожидание ошибок на выборке размера V будет просто произведением V на эту вероятность. Байесовский классификатор ошибается на объекте x с вероятностью:

$$E_B = \min\{P(1|x), P(0|x)\}$$

Условные вероятности будем считать непрерывными функциями от $x \in \mathbb{R}^m$, чтобы иметь возможность делать предельные переходы. Метод ближайшего соседа ошибается с вероятностью:

$$E_N = P(y \neq y_n)$$

Здесь y — настоящий класс x , а y_n — класс ближайшего соседа x_n к объекту x в предположении, что в обучающей выборке n объектов, равномерно заполняющих пространство.

Докажите исходное утверждение, выписав выражение для E_N (принадлежность к классам 0 и 1 для объектов x и x_n считать независимыми событиями) и осуществив предельный переход по n .

$$E_N = P(1|x_n) \cdot P(0|x) + P(0|x_n) \cdot P(1|x) \rightarrow 2P(0|x)P(1|x) =$$

$$2 \min\{P(0|x), P(1|x)\} \cdot \max\{P(0|x), P(1|x)\} \leq 2 \min\{P(0|x), P(1|x)\} = 2E_B$$